

Trabajo 1

por grupo1 formacion

Fecha de entrega: 22-nov-2023 06:46p.m. (UTC-0500)

Identificador de la entrega: 2236463685

Nombre del archivo: fpi534851_LATE_5718_198338165_Formato trabajo de Investigacion (TI3)_ANICAMAMASGO_CONTRERASCASTILLO.docx (129.29K)

Total de palabras: 5040

Total de caracteres: 28111

Prevención de la propagación de las fake news a través del Deep Learning

Renzo Jordy Anicama Masgo
Ingeniería de Software - UTP
Universidad Tecnológica del Perú
Lima, Perú
0009-0008-5507-0635

Paul Vicente Junior Contreras Castillo
Ingeniería de Software - UTP
Universidad Tecnológica del Perú
Lima, Perú
0003-0008-1507-0255

Abstract—Este documento electrónico es una plantilla "online" y ya define los componentes del artículo [título, texto, encabezados, etc.] en su hoja de estilo. *CRÍTICO: No utilice símbolos, caracteres especiales, notas a pie de página ni cálculos matemáticos en el título ni en el resumen del documento. (Abstract)

Keywords—component, formatting, style, styling, insert (key words)

I. INTRODUCTION

Ahora las personas pueden obtener noticias rápidamente a través de diversas plataformas en línea, como redes sociales, blogs y páginas web. Estas fuentes contienen una gran cantidad de contenido no verificado y no autenticado, lo que resulta en la difusión generalizada de información errónea [1]. Las noticias falsas tienen dos características: por un lado, contienen información incorrecta que podría confirmarse como tal, pero, por otro lado, se producen con la intención deshonesta de engañar a los lectores. La distribución de noticias falsas a través de las redes sociales puede tener implicaciones significativas, como socavar la confianza del público en el sistema de noticias, dañar la reputación de un individuo u organización, o generar miedo entre el público en general, todo lo cual puede afectar la estabilidad de la sociedad [2].

Según Hamed y Yaakub [3], la detección de noticias falsas es un desafío y los estudios sobre este tema aún se encuentran en una etapa incipiente. Sin embargo, la proliferación de noticias falsas está en aumento, lo que requiere un mayor desarrollo y exploración de nuevas direcciones en la investigación para mejorar las técnicas utilizadas en la identificación de dichas noticias. En los últimos años, las tecnologías de la información, como la minería de textos y los rastreadores web, han permitido que los comentarios de las redes sociales se recopilen y procesen a gran escala de forma automática y objetiva [4]. Así Shukla y Agarwal [2] indican que, para reducir los impactos dañinos de las noticias falsas, es fundamental desarrollar un sistema que pueda detectarlas automáticamente cuando aparecen en las redes sociales. La investigación actual propone un modelo que utiliza un nuevo enfoque que emplea nuevas tendencias en la detección de noticias falsas en las redes sociales mediante la utilización de características extraídas en base al análisis de sentimientos y emociones, teniendo cuidado de no descuidar los emojis en los comentarios [3].

Por ello, uno de los enfoques clave para abordar este problema es el análisis de sentimientos, una técnica que busca evaluar las emociones y actitudes expresadas en los mensajes en línea. El análisis de sentimientos se ha utilizado en la detección de desinformación con el objetivo de identificar

contenidos emocionalmente cargados que puedan ser indicativos de información falsa o engañosa.

La justificación de la revisión sistemática de literatura de esta investigación se basa en los artículos estudiados en los últimos 5 años, así como en la necesidad de aportar soluciones innovadoras y efectivas para combatir el fenómeno de las fake news. Además, se espera que el uso del Deep Learning permita mejorar el rendimiento y la precisión de los métodos existentes para la detección de las fake news, así como explorar nuevas formas de análisis y prevención. Por último, se considera que esta investigación puede tener un impacto positivo en la sociedad, al fomentar el acceso a una información veraz, plural y de calidad.

El problema que se plantea en esta investigación es cómo aplicar el Deep Learning para prevenir la propagación de las fake news. Este método es una rama de la inteligencia artificial que se basa en el uso de redes neuronales artificiales para procesar grandes cantidades de datos y extraer patrones complejos.

Sin embargo, a pesar de los avances notables en esta área, aún existen desafíos considerables en las redes sociales con un enfoque en el aprendizaje profundo. Estos desafíos incluyen la identificación temprana y precisa de la desinformación, el ajuste a las estrategias cambiantes de las personas que la difunden, la consideración de preocupaciones éticas relacionadas con la privacidad y la medición de los resultados reales de las acciones implementadas.

Por lo tanto, esta investigación tiene como objetivo analizar la investigación existente en el campo del análisis de sentimientos en la detección y prevención de la propagación de desinformación en las Redes Sociales con aprendizaje Profundo. Al hacerlo, se busca proporcionar una visión integral de los avances, desafíos y tendencias actuales en esta área crítica de investigación.

II. METODOLOGIA

A. Tipo de estudio

Para realizar esta revisión sistemática de la literatura, se siguió la metodología Prisma (Preferred Reporting Items for Systematic Reviews and Meta-Analyses), que consiste en una serie de pautas para garantizar la calidad y transparencia de los informes de revisiones sistemáticas y metaanálisis [5]. Previo a esto primero se elaboró el método PICO, que es utilizado para describir de manera precisa los componentes de una pregunta de revisión.

Para ello, se identificó los principales componentes que son:

P	Problema	Fake News
I	Intervención	Deep Learning
C	Comparación	Análisis de sentimientos
O	Resultados	Detectar y prevenir las fake news
C	Contexto	Medios Sociales

A partir de la identificación de los componentes principales se formuló la siguiente pregunta: ¿Cómo el deep learning ayuda en la detección y prevención de las fake news en los medios sociales en los últimos 5 años? y con el fin de interrogar con detalle los artículos que se revisaran, se procedió a desagregar la pregunta de revisión en preguntas asociadas a los componentes PICOC.

Requerimientos	Preguntas
RQ1	¿Cuáles son las características de las fake News?
RQ2	¿Cómo el Deep learning ayuda a detectar las fake news?
RQ3	¿Cuál es la diferencia del Deep learning con el análisis de sentimientos para detectar las fake news?
RQ4	¿Con que precisión se detectan las fake news mediante el Deep learning?
RQ5	¿Cómo actúa el Deep learning en los medios sociales?

B. Proceso de recolección de información

Para garantizar la sensibilidad del proceso de búsqueda se elaboró un cuadro detallado del método empleado, el cual nos mostrara los componentes utilizados, así como las preguntas asociadas a cada uno de ellos, las palabras clave y la ecuación de búsqueda.

Método	Palabra Clave	Ecuación de búsqueda
P	"Fake News"	"Fake News" OR Misinformation OR Post-truth
I	"Deep Learning"	"Deep Learning" OR "Machine Learning" OR "Neural network"
C	"Sentiment Analysis"	"Sentiment Analysis" OR "Text mining" OR "Opinion mining"
O	"Detection" "Prevention"	Detection OR Prevention OR "Fraud Detection"
C	"Social Network" "Social Media"	"Social Network" OR "Social Media" OR "Online Communities" OR "Digital Communication"

Por último, después de seleccionar las palabras clave de cada componente de la pregunta PICOC y relacionarlas entre sí, se elaboró la ecuación de búsqueda sistemática de literatura; el cual será aplicada en las siguientes bases de datos:

Scopus:

(TITLE-ABS-KEY ("Fake News" OR misinformation OR post-truth) AND TITLE-ABS-KEY ("Deep Learning" OR "Machine Learning" OR "Neural network") AND TITLE-ABS-KEY ("Sentiment Analysis" OR "Text mining" OR "Opinion mining") AND TITLE-ABS-KEY (detection OR prevention OR "Fraud Detection") AND TITLE-ABS-KEY ("Social Network" OR "Social Media" OR "Online Communities" OR "Digital Communication"))

Scielo:

((fake news) OR (Misinformation) or (noticias) or (noticia) OR (Post-truth) OR (noticias falsas) OR (desinformación)) AND ((Machine Learning) OR (aprendizaje automático) OR (Deep Learning) OR (Neural network) or (red neuronal))

Ebsco:

("Fake News" OR Misinformation OR Post-truth) AND ("Deep Learning" OR "Machine Learning" OR "Neural network") AND ("Sentiment Analysis" OR "Text mining" OR "Opinion mining") AND (Detection OR Prevention OR "Fraud Detection") AND ("Social Network" OR "Social Media" OR "Online Communities" OR "Digital Communication")

C. Criterios de inclusión y de exclusión

En esta RSL se establecieron criterios de inclusión y exclusión para la selección de los artículos originales publicados en bases de datos científicas indexadas.

En la siguiente tabla de criterios de inclusión se va enumerar los criterios que se han considerado.

Criterio de Inclusión	Descripción
CI1	Los estudios incluidos deben centrarse en la prevención de la propagación de las fake news, y no solo en su detección o análisis.
CI2	Los estudios deben utilizar técnicas de Deep learning para la prevención de las fake news, o que las comparen con otras técnicas más tradicionales o basadas en reglas.
CI3	Los estudios deben abordar los desafíos y limitaciones del deep learning para la prevención de las fake news, como la calidad y disponibilidad de los datos, la interoperabilidad y explicabilidad de los modelos, la ética y la privacidad de los usuarios.
CI4	Los estudios deben presentar resultados empíricos basados en datos reales o simulados, y que incluyan medidas de evaluación adecuadas, como la precisión.

Se han considerado estos criterios de inclusión por la siguiente razón:

En el primer criterio, se considera porque la investigación tiene como objetivo analizar cómo el Deep learning puede ayudar a prevenir la difusión de noticias falsas, no solo detectarlas o analizarlas. La prevención implica intervenir antes de que las noticias falsas se generalicen y requiere técnicas para identificar y bloquear las fuentes, canales y usuarios que las crean o comparten.

En el segundo criterio, se considera porque el Deep learning es una técnica avanzada de inteligencia artificial que permite la extracción y procesamiento de datos complejos y heterogéneos como texto, audio, video e imágenes, que son las formas más comunes de falsificación.

En el tercer criterio, se considera porque los aspectos mencionados en su inclusión son de suma importancia para la eficiencia y confianza del uso del Deep learning y requieren soluciones innovadoras y responsables.

En el cuarto criterio, se considera porque se puede monitorear a través de los criterios mencionados en su inclusión la efectividad y el impacto del Deep learning para evitar noticias falsas y facilitar la replicación y generalización de la investigación.

En la siguiente tabla de criterios de exclusión se va enumerar los criterios que se han considerado.

Criterio de Exclusión	Descripción
CE1	Documentos anteriores a 2019.
CE2	Las publicaciones no tienen acceso abierto.
CE3	Excluir artículos que no aborden directamente la prevención de la propagación de fake news.
CE4	Tipo de publicación NO corresponde a artículo original.
CE5	Documentos duplicados

Se han considerado estos criterios de exclusión por la siguiente razón:

En el primer criterio, se considera porque se tiene en cuenta el avance del Deep learning en los últimos años, el cual ha posibilitado el desarrollo de nuevas aplicaciones y soluciones para prevenir las fake news.

En el segundo criterio, se considera porque la investigación aspira o tiene que ser transparente y accesible para la comunidad científica y el público en general, por lo tanto, solo se incluyen las publicaciones de acceso abierto.

En el tercer criterio, se considera porque el enfoque de la investigación se centra exclusivamente en la prevención de la propagación de noticias falsas, sin considerar aspectos como la detección, el análisis, la generación o el impacto de las fake news.

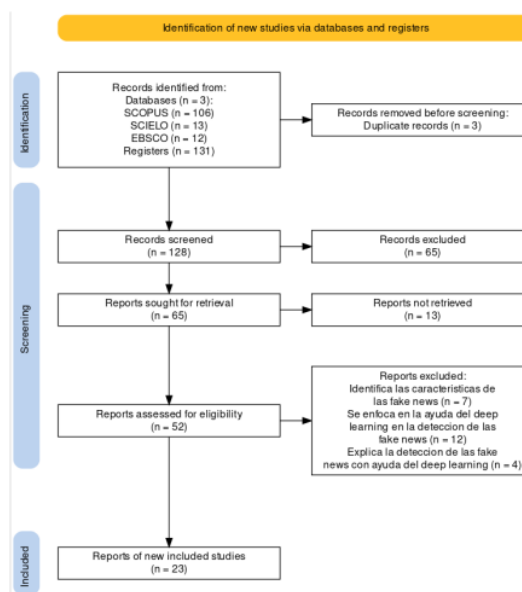
En el cuarto criterio, se considera porque la investigación tiene como objetivo obtener una visión completa y rigurosa del

Deep learning para prevenir las fake news, por lo tanto, solo se incluyen artículos originales que presenten resultados empíricos, teóricos o metodológicos sobre el tema.

En el quinto criterio, se considera porque los documentos duplicados no aportan nada nuevo a la investigación y pueden generar confusión o sesgo en el análisis de los datos. Por eso, se eliminan de la muestra de estudio.

D. Flujoograma

A partir del análisis de las 3 bases de datos indexadas scielo, scopus y ebco se registraron 131 artículos y luego de aplicar los procedimientos de criterios de elegibilidad de inclusión y exclusión se han obtenido finalmente 23 artículos.



III. RESULTADOS

Los resultados de esta investigación se siguieron a partir de las pautas la metodología PRISMA para la realización y presentación de la revisión sistemática de la literatura. Se realizaron búsquedas en 3 bases de datos indexadas y se seleccionaron estudios de 23 artículos que cumplieron los criterios de inclusión.

En la siguiente tabla se presenta una síntesis de los principales autores que han aplicado técnicas de deep learning para la detección de fake news en las redes sociales. Se indica el nombre y el aporte específico de cada autor.

Autor(es)	Aporte
Darad, Simran, Krishnan, Sridhar.	Aplicar técnicas de aprendizaje automático para predecir el sentimiento de las personas que usan las redes sociales como

	11 Twitter durante el pico de COVID-19 en abril de 2021[6].
Rojas Rubio, Luis, Meneses Villegas, Claudio	Comparar 8 empíricamente distintos algoritmos de aprendizaje automático y aprendizaje profundo para identificar noticias falsas en redes sociales[7]. 3
Alvarez-Carmona, Miguel Ángel, Aranda, Ramón.	Presentar un análisis detallado de modelos de clasificación textual para determinar el semáforo epidemiológico regional mexicano a través de noticias de COVID [8].
Shushkevich, Elena, Alexandrov, Mikhail, Cardiff, John.	Proporcionar una revisión exhaustiva de los enfoques y métodos utilizados para detectar noticias falsas relacionadas con Covid-19 [9]. 7
7 Tamayo, Antonio, Londoño, Julián, Arias, Burgos, Diego, Quiroz, Gabriel.	Explorar el uso de predicados de oraciones como características para determinar automáticamente la postura del escritor en los artículos de noticias en español [10].
Janicka, Maria, Pszona, Maria, Wawer, Aleksander.	Explorar las limitaciones de los modelos de detección de noticias falsas y la importancia de entrenar y evaluar modelos en diferentes tipos de textos [11]. 5
Bangyal, Waqas Haider; Qasim, Rukhma; Rehman, Najeeb ur; Ahmad, Zeeshan; Dar, Hafsa; Rukhsar, Laiqa; Aman, Zahra; Ahmad, Jamil.	Proponer un enfoque altamente preciso para el análisis de sentimientos de noticias falsas relacionadas con COVID-19 [12]. 1
Ahmad, Pir Noman; Liu, Yuanchao; Ali, Gauhar; Wani, Mudasir Ahmad; ElAffendi, Mohammed.	Proponer un enfoque robusto para identificar y analizar textos propagandísticos, que puede ayudar a desarrollar estrategias eficaces para combatir la desinformación en línea [13]. 10
5 Hamed, Suhaib Kh., Ab Aziz, Mohd Juzaidin, Yaakub, Mohd Ridzwan.	Presentar un modelo para detectar noticias falsas en las redes sociales, que utiliza análisis de sentimiento del contenido de las noticias y análisis de emociones de los comentarios de los usuarios [14].
1 Galende B.A., Hernandez-Penaloza G., Uribe S., Garcia F.A.	Nueva técnica llamada BORJIS para detectar teorías de conspiración en Twitter utilizando técnicas de aprendizaje profundo [15].
1 Mayopu R.G., Wang Y.-Y., Chen L.-S.	Contribuir a la comprensión de las noticias falsas de múltiples maneras y proporciona una base

	para distinguirlas de las noticias precisas [16].
23 Huu Do T., Berneman M., Patro J., Bekoulis G., Deligiannis N.	Presentar un enfoque novedoso para la detección de noticias falsas mediante la consideración tanto del contenido de la noticia como del contexto social[17].
1 Iwendi C., Mohan S., Khan S., Ibeke E., Ahmadian A., Ciano T.	Detectar noticias falsas 9 relacionadas con COVID-19 mediante el uso de técnicas de aprendizaje profundo y procesamiento del lenguaje natural (NLP) [18].
Mishra S., Shukla P., Agarwal R.	Desarrollo de modelos de aprendizaje automático para detectar noticias falsas en diferentes idiomas y dominios[19]. 10
41 Balshetwar, Sarita V; RS, Abilash; R, Dani Jermisha.	Proponer una nueva solución para detectar noticias falsas en las redes sociales utilizando análisis de sentimiento y una estrategia de imputación múltiple [20].
ALDayel A., Magdy W.	40strar diferentes aplicaciones de la detección de posturas en las redes sociales y proporciona una lista exhaustiva de los recursos existentes para la detección de posturas en la literatura [21].
1 Tashtoush Y., Alrababah B., Darwish O., Maabreh M., Alsaedi N.	Aprendizaje profundo para detectar noticias falsas relacionadas con COVID-19 en plataformas de redes sociales [22]. 8
Mahmud Y., Shaeali N.S., Mutalib S.	Rendimiento de cuatro algoritmos de aprendizaje automático para la detección de noticias falsas mediante la automatización de un modelo clasificador de sentimientos [23].
1 Uppada S.K., Manasa K., Vidhathi B., Harini R., Sivaselvan B.	Modelo llamado SENAD que utiliza patrones de interacción social de los usuarios. 22 contenido visual para mejorar la detección de noticias falsas y cuentas falsas en las redes sociales en línea [24].
30 Kaddoura S., Chandrasekaran G., Popescu D.E., Duraisamy J.H.	Técnicas que involucran Aprendizaje Automático, Aprendizaje Profundo y enfoques basados en texto para mejorar la seguridad en las redes sociales [25].
Malla S., P.J.A. A.	Realizar un Modelo de Deep Learning conjunto para clasificar tuits informativos relacionados con COVID-19, que logra una precisión de más del 91,75% [26].

1 Awan M.J., Yasin A., Nobanee H., Ali A.A., Shahzad Z., Nabeel M., Zain A.M., Shahzad H.M.F.	El enfoque híbrido que combina el análisis semántico y la inteligencia artificial con la información social basada en redes, para de 16 ar y combatir noticias falsas [27].
Umer M., Imtiaz Z., Ullah S., Mehmood A., Choi G.S., On B.-W.	Detección de noticias falsas basado en una arquitectura de aprendizaje profundo 4 CNN-LSTM que utiliza técnicas de minería de texto y análisis de sentimiento [28].

A. Figuras

En primer lugar, se presenta la “Figura 1”, donde se observan los años de publicación de los artículos en los últimos 5 años.



Figura 1. Año de publicación

El gráfico indica que el interés por este tema ha aumentado en los últimos años, especialmente en el 2021, cuando se publicaron 8 artículos. El gráfico también muestra que el año 2020 fue el menos productivo, con solo 1 artículo.

En segundo lugar, se presentará la “Figura 2”, donde se observan las bases de datos de investigación.




Figura 2. Bases de Datos de Investigación

El gráfico indica que la base de datos que se encontró más artículos con referencia a la revisión sistemática de la literatura fue ESCOPUS, con un 57%. La segunda base de datos fue EBSCO, con un 26% y la base de datos que se encontró menos artículos fue SCIELO, con un 17%.

En tercer lugar, se presenta la “Figura 3”, donde se observan el top 5 de palabras clave mencionada en los artículos seleccionados.




Figura 3. Top 5 de palabras clave

En el gráfico indica que la palabra mas mencionada en las palabras clave de los artículos es “Fake news” con un tanto de 18 veces, lo que indica que forma parte del tema principal de la investigación y la palabra clave menos mencionada es “COVID-19” con un tanto de 6 veces, lo que evidencia que no forma mucha parte del contexto para el estudio de las noticias falsas.

B. Analisis de la metodologia usada en los articulos

De acuerdo al tipo de metodología usada en cada artículo, se puede decir que las metodologías difieren en sus detalles específicos, pero 4 todas comparten un tema común: la utilización de técnicas de aprendizaje automático y aprendizaje profundo para detectar y clasificar varios tipos de contenido, como noticias falsas, spam, propaganda y teorías de conspiración, en plataformas de redes sociales como Gorrjeo. Algunas de las t 21 cas comunes utilizadas en estas metodologías incluyen redes neuronales convolucionales (CNN), redes de memoria a corto plazo (LSTM), modelos de aprendizaje profundo por conjuntos basados en votación mayoritaria (MVEDL) y análisis semántico latente (LSA). Las n 20 dologías también implican pasos como la recopilación de datos, el preprocesamiento de datos, la extracción de características y la evaluación de m 4 jelos. En general, las metodologías tienen como objetivo mejorar la precisión y efi 12 ncia de la detección y clasificación de diversos tipos de contenido en las plataformas de redes sociales.

C. Analisis especifico de las preguntas PICOC

De acuerdo a las p 19 untas PICOC se analizará la primera pregunta ¿Cuáles son las 19 acterísticas de las fake news?, los artículos coinciden que las características de las fake news incluyen ser escritas y publicadas con la intención de engañar y dañar la reputación de una entidad o persona, con el objetivo de obtener ganancias financieras o políticas. Las fake news suelen ser creadas por los llamados “fakesters”,

que crean un artículo con contenido falso que a menudo se incluye en contenido noticioso real y confiable. Aunque la información errónea o la sátira pueden ser menos engañosas, el público objetivo aún puede resultar engañado. Las noticias satíricas pueden crear intencionalmente falsas expectativas en la mente del lector al utilizar el significado tradicional de insatisfacción, tomado literalmente. La mentira está mal oculta y hay que saberla. Las fake news tienen dos características principales: en primer lugar, contienen información incorrecta que puede ser confirmada como tal; en segundo lugar, se producen con el objetivo deshonesto de engañar a los lectores.

En la segunda pregunta ¿Cómo el Deep learning ayuda a detectar las fake news? Los artículos coinciden que el Deep learning ayuda a detectar las fake news mediante el uso de modelos de aprendizaje profundo que analizan el contenido textual de artículos de noticias, titulares y publicaciones en redes sociales para identificar inconsistencias, sesgos e información engañosa. Los modelos de Deep learning pueden aprender patrones complejos en grandes conjuntos de datos, lo que puede ser difícil o imposible para los humanos. Además, se utilizan técnicas de procesamiento de lenguaje natural (NLP) y algoritmos de clasificación para identificar características específicas de las noticias falsas, como la falta de fuentes confiables o la ausencia de información engañosa. Se han utilizado varios modelos de aprendizaje profundo, como redes neuronales convolucionales (CNN), redes neuronales recurrentes (RNN) y redes neuronales de memoria a corto plazo (LSTM), para detectar noticias falsas con alta eficiencia.

En la tercera pregunta ¿Cuál es la diferencia del Deep learning con el análisis de sentimientos para detectar las fake news? Los artículos coinciden que la diferencia principal entre el Deep learning y el análisis de sentimientos para detectar fake news radica en que el Deep learning se enfoca en identificar patrones complejos en grandes conjuntos de datos para hacer predicciones precisas sobre la veracidad de la información, mientras que el análisis de sentimientos se centra en determinar la actitud emocional del autor hacia el tema de la noticia. Ambas técnicas pueden ser útiles para detectar noticias falsas, pero se utilizan de manera diferente y se enfocan en aspectos distintos del texto.

En la cuarta pregunta ¿Con qué precisión se detectan las fake news mediante el Deep learning? Según los artículos mencionan que hay una variedad de resultados en cuanto a la precisión de la detección de noticias falsas mediante el uso de técnicas de Deep Learning. Algunos estudios informan de tasas de precisión que oscilan entre el 72,3% y el 97%, dependiendo de los modelos y las técnicas específicas utilizadas. Además, se mencionan enfoques híbridos que combinan distintos modelos neuronales para mejorar la precisión en la clasificación de noticias falsas. También se destaca que la precisión puede variar según el conjunto de datos utilizado y las técnicas de Deep Learning implementadas.

En la quinta pregunta ¿Cómo actúa el Deep learning en los medios sociales? Solo cierta parte de los artículos dicen que primero se analiza el contenido textual de artículos de

noticias, titulares y publicaciones en redes sociales para identificar inconsistencias, sesgos e información engañosa. Luego se emplea el aprendizaje profundo para extraer información valiosa de tweets y actualizaciones de Facebook, incluyendo detección de información falsa, clasificación de sentimientos, identificación de temas y recomendación de contenidos. Es importante que el Deep learning utiliza de redes neuronales profundas para detectar patrones complejos en el contenido de las redes sociales, incluyendo la detección de spam y noticias falsas.


AGRADECIMIENTOS

La ortografía preferida de la palabra "reconocimiento" en Estados Unidos es sin una "e" después de la "g". Evite la expresión forzada "uno de nosotros (R. B. G.) gracias...". En su lugar, pruebe con "R. B. G. gracias...". Coloque los agradecimientos de los patrocinadores en la nota al pie sin numerar de la primera página.

REFERENCIAS

- [1] C. Mallick, S. Mishra y M. R. Senapati, "A cooperative deep learning model for fake news detection in online social networks", *J. Ambient Intell. Humanized Comput.*, febrero de 2023. Accedido el 11 de septiembre de 2023. [En línea]. Disponible: <https://doi.org/10.1007/s12652-023-04562-4>
- [2] S. Mishra, P. Shukla y R. Agarwal, "Analyzing machine learning enabled fake news detection techniques for diversified datasets", *Wireless Commun. Mobile Comput.*, vol. 2022, pp. 1–18, marzo de 2022. Accedido el 11 de septiembre de 2023. [En línea]. Disponible: <https://doi.org/10.1155/2022/1575365>
- [3] S. K. Hamed, M. J. A. Ab Aziz y M. R. Yaakub, "Fake news detection model on social media by leveraging sentiment analysis of news content and emotion analysis of users' comments", *Sensors*, vol. 23, n.º 4, p. 1748, febrero de 2023. Accedido el 11 de septiembre de 2023. [En línea]. Disponible: <https://doi.org/10.3390/s23041748>
- [4] J.-Y. Huang, C.-L. Tung y W.-Z. Lin, "Using social network sentiment analysis and genetic algorithm to improve the stock prediction accuracy of the deep learning-based approach", *Int. J. Comput. Intell. Syst.*, vol. 16, n.º 1, mayo de 2023. Accedido el 11 de septiembre de 2023. [En línea]. Disponible: <https://doi.org/10.1007/s44196-023-00276-9>
- [5] J. E. McKenzie, M. J. Page, P. M. Bossuyt et al., "The PRISMA 2020 statement: an updated guideline for reporting systematic reviews", *BMJ [Online]*, vol. 372, no. n71, pp. 1–9, 2021.
- [6] S. Darad y S. Krishnan, "Sentimental analysis of COVID-19 twitter data using deep learning and machine learning models", *Ingenius*, n.º 29, pp. 108–117, enero de 2023. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.17163/ings.n29.2023.10>
- [7] L. Rojas Rubio y C. Meneses Villegas, "Una comparación empírica de algoritmos de aprendizaje automático versus aprendizaje profundo para la detección de noticias falsas en redes sociales", *Ingeniare. Rev. Chil. Ing.*, vol. 30, n.º 2, pp. 403–415, junio de 2022. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.4067/s0718-33052022000200403>
- [8] M. Á. Álvarez-Carmona y R. Aranda, "Determinación automática del color del semáforo mexicano del COVID-19 a partir de las noticias", 2022. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1590/SciELOPreprints.3834>
- [9] E. Shushkevich, M. Alexandrov y J. Cardiff, "Covid-19 fake news detection: A survey", *Computación y Sist.*, vol. 25, n.º 4, diciembre de 2021. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.13053/cys-25-4-4089>

- [10] A. Tamayo, J. Arias Londoño, D. Burgos y G. Quiroz, "Sentiment analysis of news articles in spanish using predicate features", *Lenguaje*, vol. 47, n.º 2, pp. 235–267, julio de 2019. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.25100/lenguaje.v47i2.7937>
- [11] M. Janicka, M. Pszona y A. Wawer, "Cross-Domain failures of fake news detection", *Computación y Sist.*, vol. 23, n.º 3, octubre de 2019. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.13053/cys-23-3-3281>
- [12] W. H. Bangyal *et al.*, "Detection of fake news text classification on COVID-19 using deep learning approaches", *Comput. Math. Methods Medicine*, vol. 2021, pp. 1–14, noviembre de 2021. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1155/2021/5514220>
- [13] P. N. Ahmad, Y. Liu, G. Ali, M. A. Wani y M. ElAffendi, "Robust benchmark for propagandist text detection and mining high-quality data", *Mathematics*, vol. 11, n.º 12, p. 2668, junio de 2023. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.3390/math11122668>
- [14] S. K. Hamed, M. J. A. Ab Aziz y M. R. Yaakub, "Fake news detection model on social media by leveraging sentiment analysis of news content and emotion analysis of users' comments", *Sensors*, vol. 23, n.º 4, p. 1748, febrero de 2023. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.3390/s23041748>
- [15] B. A. Galende, G. Hernandez-Penaloza, S. Uribe y F. A. Garcia, "Conspiracy or not? A deep learning approach to spot it on twitter", *IEEE Access*, vol. 10, pp. 38370–38378, 2022. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1109/access.2022.3165226>
- [16] R. G. Mayopu, Y.-Y. Wang y L.-S. Chen, "Analyzing online fake news using latent semantic analysis: Case of USA election campaign", *Big Data Cogn. Comput.*, vol. 7, n.º 2, p. 81, abril de 2023. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.3390/bdcc7020081>
- [17] T. Huu Do, M. Berneman, J. Patro, G. Bekoulis y N. Deligiannis, "Context-Aware deep markov random fields for fake news detection", *IEEE Access*, vol. 9, pp. 130042–130054, 2021. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1109/access.2021.3113877>
- [18] C. Iwendi, S. Mohan, S. Khan, E. Ibeke, A. Ahmadian y T. Ciano, "Covid-19 fake news sentiment analysis", *Comput. Elect. Eng.*, p. 107967, abril de 2022. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1016/j.compeleceng.2022.107967>
- [19] S. Mishra, P. Shukla y R. Agarwal, "Analyzing machine learning enabled fake news detection techniques for diversified datasets", *Wireless Commun. Mobile Comput.*, vol. 2022, pp. 1–18, marzo de 2022. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1155/2022/1575365>
- [20] S. V. Balshetwar, A. Rs y D. J. R., "Fake news detection in social media based on sentiment analysis using classifier techniques", *Multimedia Tools Appl.*, marzo de 2023. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1007/s11042-023-14883-3>
- [21] A. ALDayel y W. Magdy, "Stance detection on social media: State of the art and trends", *Inf. Process. & Manage.*, vol. 58, n.º 4, p. 102597, julio de 2021. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1016/j.ipm.2021.102597>
- [22] Y. Tashtoush, B. Alrababah, O. Darwish, M. Maabreh y N. Alsaedi, "A deep learning framework for detection of COVID-19 fake news on social media platforms", *Data*, vol. 7, n.º 5, p. 65, mayo de 2022. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.3390/data7050065>
- [23] Y. Mahmud, N. S. Shaeali y S. Mutalib, "Comparison of machine learning algorithms for sentiment classification on fake news detection", *Int. J. Adv. Comput. Sci. Appl.*, vol. 12, n.º 10, 2021. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1q4569/ijacsa.2021.0121072>
- [24] S. K. Uppada, K. Manasa, B. Vidhathi, R. Harini y B. Sivaselvan, "Novel approaches to fake news and fake account detection in OSNs: User social engagement and visual content centric model", *Social Netw. Anal. Mining*, vol. 12, n.º 1, mayo de 2022. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1007/s13278-022-00878-9>
- [25] S. Kaddoura, G. Chandrasekaran, D. Elena Popescu y J. H. Duraisamy, "A systematic literature review on spam content detection and classification", *PeerJ Comput. Sci.*, vol. 8, enero de 2022, art. n.º e830. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.7717/peerj-cs.830>
- [26] S. Malla y A. P.j.a., "COVID-19 outbreak: An ensemble pre-trained deep learning model for detecting informative tweets", *Appl. Soft Comput.*, vol. 107, p. 107495, agosto de 2021. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1016/j.asoc.2021.107495>
- [27] M. J. Awan *et al.*, "Fake news data exploration and analytics", *Electronics*, vol. 10, n.º 19, p. 2326, septiembre de 2021. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.3390/electronics10192326>
- [28] M. Umer, Z. Imtiaz, S. Ullah, A. Mehmood, G. S. Choi y B.-W. On, "Fake news stance detection using deep learning architecture (CNN-LSTM)", *IEEE Access*, vol. 8, pp. 156695–156706, 2020. Accedido el 9 de octubre de 2023. [En línea]. Disponible: <https://doi.org/10.1109/access.2020.3019735>



Trabajo 1

INFORME DE ORIGINALIDAD

19%

INDICE DE SIMILITUD

17%

FUENTES DE INTERNET

8%

PUBLICACIONES

6%

TRABAJOS DEL
ESTUDIANTE

FUENTES PRIMARIAS

1

www.mdpi.com

Fuente de Internet

2%

2

Submitted to Universidad Tecnologica del
Peru

Trabajo del estudiante

2%

3

www.researchgate.net

Fuente de Internet

1%

4

rua.ua.es

Fuente de Internet

1%

5

pesquisa.bvsalud.org

Fuente de Internet

1%

6

github.com

Fuente de Internet

1%

7

search.scielo.org

Fuente de Internet

1%

8

docs.google.com

Fuente de Internet

1%

9

e-archivo.uc3m.es

Fuente de Internet

1 %

10

article.wn.com

Fuente de Internet

1 %

11

dspace.ups.edu.ec

Fuente de Internet

<1 %

12

issuu.com

Fuente de Internet

<1 %

13

juandomingofarnos.wordpress.com

Fuente de Internet

<1 %

14

repositorio.unal.edu.co

Fuente de Internet

<1 %

15

hdl.handle.net

Fuente de Internet

<1 %

16

[Submitted to Middlesex University](#)

Trabajo del estudiante

<1 %

17

apromar.es

Fuente de Internet

<1 %

18

docplayer.es

Fuente de Internet

<1 %

19

Olga Demushina, Yulia Semikina.
"Coronavirus fake news in Russia: specificity
and criteria for detection", Rizoma, 2020

Publicación

<1 %

20	Submitted to Universidad Internacional de la Rioja	<1 %
Trabajo del estudiante		

21	1library.co	<1 %
Fuente de Internet		

22	Submitted to Universidad Autónoma de Nuevo León	<1 %
Trabajo del estudiante		

23	link.springer.com	<1 %
Fuente de Internet		

24	repositori.uji.es	<1 %
Fuente de Internet		

25	www.coursehero.com	<1 %
Fuente de Internet		

26	V. Daien, A. Muyl-Cipollina. "Le Big Data peut-il changer nos pratiques?", Journal Français d'Ophtalmologie, 2019	<1 %
Publicación		

27	lab.cccb.org	<1 %
Fuente de Internet		

28	lopublico.redbogota.com	<1 %
Fuente de Internet		

29	mes.openaire.eu	<1 %
Fuente de Internet		

peerj.com

30

Fuente de Internet

<1 %

31

www.auladeeconomia.com

Fuente de Internet

<1 %

32

www.erudit.org

Fuente de Internet

<1 %

33

Submitted to Tilburg University

Trabajo del estudiante

<1 %

34

so.iaa.csic.es

Fuente de Internet

<1 %

35

www.creces.cl

Fuente de Internet

<1 %

36

editorialeidec.com

Fuente de Internet

<1 %

37

repositorio.cepal.org

Fuente de Internet

<1 %

38

repositorio.ufsc.br

Fuente de Internet

<1 %

39

repositorio.upn.edu.pe

Fuente de Internet

<1 %

40

revistas.ulasalle.edu.pe

Fuente de Internet

<1 %

41

vufind.katalog.k.utb.cz

Fuente de Internet

<1 %

Excluir citas

Apagado

Excluir coincidencias

Apagado

Excluir bibliografía

Activo